

國立中興大學資訊工程學系

資訊專題競賽報告

人工智慧是否能理解未見過的語言？

(Can AI understand unseen languages? YES)

專題題目說明、價值與貢獻自評（限100字內）：

研究探索大型語言模型(LLMs)在面對未知語言句子結構時的翻譯能力，透過構建語法多樣的人工語言，並提供動態語境參考，實驗發現LLMs能利用有限資源學習解讀新的語言，展現其在保護稀有語言及促進跨文化溝通上的潛力。

專題隊員：


姓名	E-mail	負責項目說明	專題內貢獻度(%)
李曉旻	siaommmmin10@gmail.com	組合整個實驗結構及流程設計，報告撰寫	100%

【說明】上述表格之專題內貢獻度累計需等於100%。

指導教授簡述及簡評：

曉旻主要研究現有的大型語言模型是否可以透過In-Context Learning與字典的使用來進行未知語言的理解。曉旻主要利用Context-Free Grammar來進行語言的生成(以為虛構語言)，並進行大量實驗來進行大型語言模型行為的觀察。過程中，有許多研究洞見，是一個十分有趣的研究，我個人十分推薦。

指導教授簽名：



中 華 民 國 年 月 日

目錄

- 一、 摘要（含關鍵詞）
- 二、 專題研究動機與目的
- 三、 專題重要貢獻
- 四、 團隊合作方式
- 五、 設計原理、研究方法與步驟
- 六、 系統實現與實驗
- 七、 效能評估與成果
- 八、 結論
- 九、 參考文獻

一、 摘要（含關鍵詞）

這項研究專注於 LLM 對於未知語言句子結構的理解，我們定義了全新的語法結構，並按照特定規則對詞彙順序進行了打亂，並進行加密，同時，我們運用了動態語境檢索技術，給予 LLM 參考資料，幫助其找出正確的語法排序結構規則。本研究旨在探討 LLM 對未知語言句子結構的理解能力，以應對跨文化交流和語言多樣性所帶來的挑戰，我們期望 LLM 能夠利用有限的語言資源，在未來對世界各地瀕危的稀少語言進行更多與母語保存相關的貢獻。

Keywords:大型語言模型、構造語言、語言理解、句子結構、動態語境檢索

二、 專題研究動機與目的

LLM（大型語言模型）已經在廣泛使用的語言翻譯方面取得了革命性的進展。然而，對於不太常見、代表性不足的語言，LLM 的有效性卻了解得較少，最近的研究顯示，LLMs 可以使用額外的資源，如數據庫，來解決問題。它們甚至可以指導自己如何最好地使用這些資源[1]。受此啟發，我們為 LLMs 提供了示例和翻譯方法，以幫助它們在語言翻譯任務中表現更好，提供了對 LLM 在這一領域潛力的進一步洞察。

隨著人工智能技術的快速發展，LLM（大型語言模型）已經成為自然語言處理領域的強大工具，在語言翻譯[2]、文本生成和詞語理解等任務中表現出色。它們的穩健性能引發了進一步探索其能力的興趣，特別是在解

讀和翻譯結構和語法多樣性的語言之間。

本研究評估 LLM 在處理特殊構建語言下的表現，採用動態語境檢索技術和加密詞彙等方法，為 LLM 提供有針對性的參考信息，也透過引入加密詞彙和詞性提示等手段，模擬了 LLM 面對全新語言時的真實情況。

研究結果表明，利用適當的上下文示例和結構化提示，LLM 可以有效應對複雜語言翻譯的挑戰，包括對於資源匱乏語言的情況，展示了 LLM 在解決複雜語言翻譯中具有潛力，並隨著訓練語料規模的增加而性能提升，此研究有助於保護和振興瀕危語言。

三、 專題重要貢獻

1. 設計一種基於無關文法(CFG)的構建語言，用於生成語法多樣的句子結構,模擬 LLM 面對全新語言的情況。
2. 實作動態語境檢索技術，為 LLM 提供與查詢句子在詞性結構上最相似的語料庫句子作為參考。
3. 評估 GPT-3.5 和 GPT-4 在不同規模的構建語言數據集上的翻譯能力，探索了 LLM 對未知語言結構的理解和模仿能力。
4. 實驗結果表明，LLM 可以借助適當的上下文示例和結構化提示來解決複雜語言翻譯的挑戰,並隨著訓練數據規模的增加而逐步提升性能。

5. 研究突顯了 LLM 應用於低資源語言和合成語言的潛力，為利用 AI 技術保護和振興瀕危語言提供了新思路。

四、 團隊合作方式

此專題分成三個部分，語句生成、動態語境檢索及提示策略實驗，皆為李曉旻同學一人負責。

五、 設計原理、研究方法與步驟

我們設計了一種基於上下文無關文法的人工構築語言，用於產生各種語法多樣的句子結構以進行評估。

1. CFG Language 的生成

語言的構建遵循以下文法。

$$\begin{aligned} S &\rightarrow VP\ NP \\ VP &\rightarrow V\ NP \mid V\ NP\ PP \mid V \\ NP &\rightarrow Det\ N \mid Det\ N\ PP \mid Pronoun \\ PP &\rightarrow Prep\ NP \end{aligned}$$

一個句子（S）包括一個動詞短語（VP）和一個名詞短語（NP）。

VP 可做變化，包括一個帶有或不帶有 NP 的動詞，或者帶有額外的介詞短語（PP）的 NP。

NP 可以包含一個限定詞（Det）和一個名詞（N），帶有可選擇的 PP，或者僅為一個代詞。

PP 將一個介詞 (Prep) 與一個 NP 結合起來。

在語法規則的最底層也相繼對應每個詞性擁有的單字，對於每一句句子可做彈性的選擇單字。這些規則系統地生成了構建語言中的句子結構。

1a. 詞彙來源

為了進行語言生成，我們使用了一個包含 201 個隨機標記的詞彙。

每個詞性 (Part of Speech, PoS) 分配的總標記數如下：23 個限定詞

(det)、50 個名詞 (n)、53 個動詞 (v)、41 個副詞 (adv)、13 個介詞 (prep) 和 21 個代詞。

1b. 數據集生成

使用上述文法，我們生成了三個不同的數據集，分別包含 100、1,000 和 10,000 對不重複的句子，作為數據集，反映了 CFG 所允許的各種組合。在 100 個句子的集合中，我們隨機選取了 10 對句子作為查詢句子，其餘 90 句為檢索用語料，對於 1,000 句子集合，則選取了 100 對句子作為查詢句子，其餘 900 句為檢索用語料，而相似地，10,000 句子集合則選取了 100 對句子作為查詢句子，並以其餘 9900 句為檢索用語料。

1c. 目標語言構建


對於目標語言，我們設計了一個基於源句子解析樹的轉換過程。從每棵樹的根節點開始，如果一個節點擁有兩個子節點，則這些子節點將會被戶香交換，反之則不做任何更動，過程會遞迴的應用到樹中的所有節點，直到每個節點都被評估並相應地做出調整，調整應用如下圖一程式碼流程所示。

Algorithm 1 Language Transformation Based on Modified Syntax Tree


```
1: function TRANSFORMSENTENCE(node)
2:   if node has no children then
3:     return
4:   end if
5:   if node has two children then
6:     left, right  $\leftarrow$  node.left child, node.right child
7:     node.left child  $\leftarrow$  right
8:     node.right child  $\leftarrow$  left
9:   end if
10:  for child in node.all children do
11:    TRANSFORMSENTENCE(child)
12:  end for
13: end function
```

圖一、語法樹調節流程

在所有節點交換完成後，所得到的句子被指定為目標語言句子。這種方法使我們能夠創建源句子的結構化但不同版本，保持語法的正確性，同時改變句子結構以滿足我們測試的目的，如下圖二轉換為下圖三之語法樹。



圖二、源語句的語法樹




圖三、圖二中源語句所對應的目標語言語法樹

2. 構建語言中的檢索

在收到查詢句子後，將首先比較每個語料庫句子中的第一個單詞的詞性（Part of Speech, PoS）與查詢的初始單詞的詞性。在這個位置上匹配的詞性標籤將為語料庫句子生成一個得分。這個比較過程將依次應用於後續的單詞：第二個單詞的詞性、第三個單詞的詞性等將與查詢中對應位置的單詞進行匹配。此外，我們還設置了一個長度限制，確保從語料庫檢索的句子不會超過查詢的長度。

為了幫助語言模型，我們從語料庫中提取並提供了與每個查詢在詞性結構上最接近的 10 個句子，流程如下圖四。



圖四、動態檢索實驗流程圖

3. 評分機制

我們使用標準的 BLEU [4] 作為效能指標。

BLEU (Bilingual Evaluation Understudy) 分數是一種常用於評估機器翻譯質量的方法，主要通過比較機器翻譯的輸出與一個或多個人工翻譯的參考文本來計算相似度，下面是其主要計算步驟：

3a. N-gram 重合度：

首先，計算機器翻譯輸出中的 n-gram (一組連續的 n 個詞) 與參考翻譯中的 n-gram 的匹配程度，這裡的 n 通常從 1 到 4，包括單詞 (1-gram)、雙詞 (2-gram)、三詞 (3-gram) 和四詞組合 (4-gram)。

3b. 精確率計算：

對於每個 n-gram，計算其在機器翻譯輸出中出現的次數與它在參考翻譯中出現次數的最小值的總和，再除以機器翻譯輸出中該 n-gram 的總次數。這樣可以避免重複計算過多的相同 n-gram。

3c. 幾何平均和補償：

將不同 n-gram 的精確率取幾何平均，並根據機器翻譯輸出的長度進行補償。如果機器翻譯輸出比參考翻譯短，會引入一個稱為 brevity penalty 的因子，以降低過短輸出的分數。

3d. 計算 BLEU 分數：

BLEU 分數的計算公式如下：

$$\text{BLEU} = \text{brevity penalty} \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

其中 p_n 是 n-gram 的精確率， w_n 是權重，N 是 n-gram 的最大長度，這個分數範圍從 0 到 1，其中 1 表示語句之間完美的匹配，反之則毫無相關。

六、系統實現與實驗


完整實驗實行流程如圖五所演示。

1. 模型使用

本實驗使用了 gpt-4-0125-preview 以及 gpt-3.5-turbo-16k-0613 版本

2. 提示詞策略

基於以上的五.1 所介紹的 CFG Language 資料的生成，將 100 筆資料集隨機切割出的 10 對目標語句分別使用五.2 的方法檢索出的與目標句最相關的 10 對語句作為給大型語言模型的 Prompt，讓語言模型觀察提示句之間的關聯性，並對目標語句做出相應的結構轉換。



圖五、實驗實現流程演示圖

七、效能評估與成果

100 Sentences				
	BLEU1	BLEU2	BLEU3	BLEU4
GPT3.5	0.9805	0.5610	0.2877	0.0104
GPT4	0.9912	0.6210	0.2877	0.4408
1000 Sentences				
GPT3.5	0.9918	0.6679	0.3782	0.1692
GPT4	0.9941	0.7817	0.5682	0.3367
10000 Sentences				
GPT3.5	0.9900	0.6498	0.3686	0.1733
GPT4	0.9946	0.8023	0.6404	0.4308

表一、不同資料集規模下的 CFG 語言學習表現

實驗結果如表一所示，對我們的 LLM 在不同大小的構建 CFG 語言數據集上的可擴展性和有效性提供了深入的洞察。值得注意的是，儘管數據集大小不同，GPT-4 在所有 BLEU 指標上的性能始終優於 GPT-3.5，突顯了新一代模型底層架構的進步。

在結果中可觀察到的一個明顯趨勢是模型性能隨著數據集大小的增加而提升。例如，無論是 GPT-3.5 還是 GPT-4，在從 100 到 10,000 句子的過程中，BLEU 分數都呈現逐步提高的趨勢。這一現象表明，模型對構建語言的結構模式的理解和複製能力隨著對更多數據的接觸而提升，從而增強了學習和泛化能力。

實驗數據顯示了兩個模型在 BLEU4 分數上表現的明顯差異。這些分數評估了模型翻譯較長單詞序列的能力，表明 GPT-4 對句子結構和上下文的理解更為深刻。值得注意的是，GPT-4 在不斷增加的數據集中保持較高的 BLEU4 分數，展示了其韌性和穩健性。這種韌性在較大的數據集中尤其明顯，突顯了 GPT-4 對複雜語言模式的精密理解。

八、 結論

研究結果顯示，隨著資料集規模的增加，模型準確度亦隨之提升，顯示出 LLM 在資料量擴展方面的有效性。我們透過構建 CFG 語言，探索 LLM 理解和翻譯未知語言結構的潛力，實驗中的 LLM 展現出解讀和語言結構重組的潛力，為其在跨語言應用中的應用提供了可能性，結果突顯了 LLM 的可擴展性和韌性，特別是 GPT-4 模型在各項 BLEU 指標上優於 GPT-3.5，凸顯了新一代模型在結構理解方面的進步，這種能力將為語言保護和跨文化交流提供了新的可能性。

結果證實了 LLM，尤其是更先進的 GPT-4，能夠處理從 CFG 生成的構建語言的假設。隨著數據集大小的逐步增加，BLEU 分數的進步也凸顯了 LLM 在學習語法模式方面的潛力，這對於它們應用於低資源或合成語言可能是至關重要的。此外，與 GPT-4 相關的更高 BLEU 分數表明，隨著 LLM 的演進，它們解讀複雜語法結構並生成連貫翻譯的能力變得更加突出。

九、 参考文献

- [1] Tatsuro Inaba, Hirokazu Kiyomaru, Fei Cheng, and Sadao Kurohashi. Multitoolcot: Gpt-3 can use multiple external tools with chain of thought prompting. arXiv preprint arXiv:2305.16896,2023.
- [2] Wenhao Zhu, Hongyi Liu, Qingxiu Dong, Jingjing Xu, Lingpeng Kong, Jiajun Chen, Lei Li, and Shujian Huang. Multilingual machine translation with large language models: Empirical results and analysis. arXiv preprint arXiv:2304.04675, 2023.
- [3] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. Bleu: a method for automatic evaluation of machine translation. In Proceedings of the 40th annual meeting of the Association for Computational Linguistics, pages 311–318, 2002.
- [4] Rui Yang, Lin Song, Yanwei Li, Sijie Zhao, Yixiao Ge, Xiu Li, and Ying Shan. Gpt4tools: Teaching large language model to use tools via selfinstruction. arXiv preprint arXiv:2305.18752,2023.